

6 курс М05-412в, кафедра “Облачные технологии” МТС

Физтех-школа прикладной математики и информатики МФТИ





Аннотация

- › В данной работе исследуется проблема прогнозирования отказов внешних накопителей данных в условиях быстрого роста облачных инфраструктур и существенных экономических рисков для крупных операторов, таких как МТС Облако. На фоне высоких масштабов эксплуатации, ежегодных убытков из-за простоев и ограничений SLA, задача предсказания отказов становится принципиально значимой для оптимизации расходов и повышения устойчивости предоставляемых сервисов.

В работе реализован формальный подход, сочетающий байесовское моделирование вероятности отказа накопителя на основе телеметрии SMART и экономико-ориентированную оптимизацию политики обслуживания. Построены и сопоставлены два класса моделей: CatBoost с апостериорным сэмплированием и байесовская нейронная сеть. Для каждого диска формируется вероятностное предсказание риска сбоя, что позволяет количественно учитывать эпистемическую и алеаторную неопределённость.

Экономическая составляющая включает симуляцию разных стратегий замены дисков с учётом стоимости плановой замены и штрафов за отказ диска, а также использование метрики условного риска CVaR для контроля убытков в наиболее неблагоприятных сценариях. Оптимальные параметры политики выбираются на фронте Парето с помощью многокритериальной оптимизации (NSGA-II), что обеспечивает баланс между минимизацией экономических потерь и эксплуатационной нагрузкой на инфраструктуру. Практическая проверка на открытых и отраслевых данных подтвердила применимость предложенного решения: достигается одновременное снижение прямых расходов и ограничение риска SLA-потерь по сравнению с классическими подходами, основанными на точечных прогнозах. Модульная архитектура методики облегчает внедрение в производственные стеки мониторинга и позволяет расширять учёт факторов риска за счёт новых источников данных. Работа закладывает фундамент для создания адаптивных систем управления надёжностью облачных хранилищ, способных поддерживать оптимальный уровень сервиса в условиях роста масштабов и сложности инфраструктуры





Содержание

- › Актуальность
- › Основные термины и определения
- › Постановка задачи
- › Существующие решения
- › Данные
- › Baseline модель
- › CatBoost модель
- › Учет экономических рисков
- › Оптимизация
- › Сравнение результатов
- › Итоги и дальнейшие планы



Актуальность

- › Типичный уровень отказов накопителей **~1%** в год;
На масштабе облака МТС это десятки и сотни сбоев ежегодно;
Например, у Backblaze ~5 выходов из строя в день при 260k дисков;
- › Отказ накопителя провоцирует
 - внеплановые затраты на замену
 - нагрузку на L2 поддержку
 - деградацию производительности кластера.
- › Непредсказуемые сбои усложняют планирование емкости и могут нарушить SLA





Основные термины и определения

$$p_i = P(\text{отказ}_{i, t_0 \leq t \leq t_0 + H} = 1 \mid x_i)$$

$$\sigma_i^2 = \text{Var}(p_i \mid x_i)$$

$$X = (\tau_{\text{замены}}, S, Q),$$

где S - минимально допустимый запас на складе, Q - размер заказа



Основные термины и определения

$$\text{CVaR}\alpha = \mathbb{E}[L \mid L \geq \text{VaR}\alpha]$$

где:

- $\text{CVaR}\alpha$ — условная стоимость под риском на уровне доверия α ;
- $\mathbb{E}[L \mid L \geq \text{VaR}\alpha]$ — математическое ожидание потерь L при условии, что они превышают значение $\text{VaR}\alpha$;
- $\text{VaR}\alpha$ — стоимость под риском на уровне доверия α , то есть пороговое значение потерь, которое не будет превышено с вероятностью α .

Постановка задачи

Найти $X^* \in \mathcal{X}$, максимизирующий функционал качества распределения прибыли Π_X ,

$$\Pi_X \sim \mathcal{L}(\Pi(X; \omega)), X^* \in \arg \max_{X \in \mathcal{X}} \left(\mathbb{E}[\Pi(X)], \text{CVaR}_\alpha(\Pi(X)) \right),$$

$$\text{где } \mathcal{X} = \{(\tau, s, q) : \tau \in [0, 1], s \geq 0, q \geq 1\},$$

$$\text{CVaR}_\alpha(\Pi(X)) = \frac{1}{K} \sum_{j=1}^K \Pi_{(j)}(X), \quad K = \lceil \alpha M \rceil, \quad \Pi_{(1)}(X) \leq \dots \leq \Pi_{(M)}(X).$$



Существующие решения

- › Точечный прогноз (MTBF, AFR)
- › Регрессии (Cox Proportional Hazard, AFT)
- › Байесовские модели (BNN/Catboost)


Ключевая идея в моей работе: связать вероятностный прогноз отказа, экономическую модель и многокритериальную оптимизацию в единой схеме.

Данные

- У разных производителей некоторые из метрик могут отличаться по смыслу
- Не все метрики влияют на вероятность отказа диска

Kaplan-Meier Life Expectancy Curves for Select Backblaze 4TB Drives

Source: Backblaze Drive Stats data from 4/2013 through 3/2022 inclusive, as of 31 March 2022



MFG	MODEL	DRIVES IN OPERATION	LIFETIME DRIVE FAILURES	LIFETIME DRIVE DAYS	LIFETIME AFR
HGST	HMS5C4040BLE640	12,728	343	30,025,871	0.40%
Seagate	ST4000DM000	18,495	4,581	68,104,520	2.45%

[6] <https://doi.org/10.1016/j.mlwa.2021.100042>

Table 1

Descriptions of relevant SMART metrics.

SMART	Attribute name	Description
3	Spin-up time	Average time (in milliseconds) of spindle spin up from zero RPM to fully operational.
5	Reallocated sectors count	Count of bad sectors that have been found and reallocated. A hard drive which has had a reallocation is very likely to fail in the immediate months.
7	Seek error rate	Rate of seek errors of the magnetic heads, due to partial failure in the mechanical positioning system.
187	Reported uncorrectable errors	Count of errors that could not be recovered using hardware ECC (Error-Correcting Code), a type of memory used to correct data corruption errors.
188	Command timeout	Count of aborted operations due to hard drive timeout.
190	Temperature difference	Difference between current hard drive temperature and optimal temperature of 100°C.
197	Current pending sectors count	Count of bad sectors that have been found and waiting to be reallocated, because of unrecoverable read errors.
198	Offline uncorrectable sectors count	Total count of uncorrectable errors when reading/writing a sector, indicating defects of the disk surface or problems in the mechanical subsystem.



Данные

- Единица наблюдения: disk_id во времени.
- Признаки: SMART, возраст, тип накопителя.
- Цель: failure@H (отказ в следующие H дней).
- Валидность: разбиение train-test по времени и контроль утечки по disk_id.

1. Реальные данные: Backblaze + LinuxHW

	date	serial_number	model	capacity_bytes	failure	datacenter	cluster_id	vault_id	pod_id	pod_slot_num
0	2024-12-22	S2ZYJ9GGB01000	ST500LM012 HN	500107862016	0	sac0	0	1028	0	NaN
1	2024-12-22	VKH7A84X	HGST HUH728080ALE600	8001563222016	0	sac0	0	1028	0	22.0
2	2024-12-22	ZA106RPJ	ST8000DM002	8001563222016	0	sac0	0	1028	0	28.0
3	2024-12-22	ZA106YX1	ST8000DM002	8001563222016	0	sac0	0	1028	0	23.0
4	2024-12-22	ZA106Z5M	ST8000DM002	8001563222016	0	sac0	0	1028	0	39.0

2. Синтетические данные: каждый атрибут задан некоторым распределением



Baseline модель

- Baseline: Weibull AFT модель.
- Оценка функции выживаемости $S(t|x)$.
- Целевая вероятность: отказ на горизонте H при условии выживания до t .

$$S(t | x_i) = \exp \left[- \left(\frac{t}{\lambda(x_i)} \right)^k \right], \quad \lambda(x_i) = \exp(\beta_0 + x_i^\top \beta), \quad k = \frac{1}{\sigma}.$$



CatBoost модель

- Основная модель: виртуальный ансамбль CatBoost по bootstrap-подвыборкам.
- Для каждого диска получаем среднее и дисперсию для вероятности отказа
- Получаем неуверенность предсказания для каждого диска

```
1 model = CatBoostClassifier(iterations=300,  
2                             depth=6,  
3                             learning_rate=0.1,  
4                             loss_function='Logloss',  
5                             posterior_sampling=True,  
6                             verbose=False)  
7 model.fit(X_feat, y_fail)  
8 res = model.virtual_ensembles_predict(X_feat, virtual_ensembles_count=100, prediction_type="VirtEnsembles")
```



Учет экономических рисков

- Прибыль учитывает закупку, хранение, аварийную замену и простой.
- Правило замены: если $p_i > \tau$, выполняется превентивная замена.
- Правило пополнения: при остаток на складе $\text{stock} < \text{safety_stock}$ заказывается q дисков.
- Экономические параметры моделируются как случайные величины.

Обозначим:

- $d_i = \mathbf{1}\{p_i > \tau\}$,
- $Z_i \mid p_i \sim \text{Bernoulli}(p_i)$,
- $u_i = d_i + (1 - d_i)Z_i$ — расход запасной единицы на диск i .

Тогда:

$$\Pi(X, \omega) = \sum_{i=1}^N \left(R_i - d_i C_i^{\text{prev}} - (1 - d_i) Z_i C_i^{\text{fail}} \right) - C_{\text{order}}(X, \omega) - C_{\text{hold}}(X, \omega).$$

$$C_i^{\text{prev}} = c_{\text{repl}} + c_{\text{pur}} - v_{\text{salv}}, \quad C_i^{\text{fail}} = c_{\text{emerg}} + c_{\text{down}} + c_{\text{pur}} - v_{\text{salv}}.$$







Оптимизация

- Метод: NSGA-II (pymoo) для двух целевых функций.
- Используем MCMC семплирование для фиксированной политики
- Результат: Pareto-front вместо единственного решения.
- Выбираются risk-neutral, risk-averse и компромисная политики.
- Интерпретация выполняется в пространстве решений доходность-риск



Сравнение результатов





Итоги и дальнейшие планы

- › Реализован framework для получения расписания замены дисков и продемонстрированы преимущества байесовского подхода.

Дальнейшие планы

- › Калибровка распределений затрат на реальных коммерческих данных
- › Внедрить онлайн режим, где прогноз и политика обновляется по мере поступления новых наблюдений
- › Внедрить в перспективе production-ready решение для облака МТС



Список литературы

1. <https://www.backblaze.com/cloud-storage/resources/hard-drive-test-data>
2. <https://github.com/linuxhw/SMART/tree/master>
3. S. Guo, H. Li, Y. Dong, J. Li, Y. Song and J. Xie, "A Reliability Evaluation Model for Smart Meters Based on Survival Analysis Theory," 2023 4th International Conference on Big Data, Artificial Intelligence and Internet of Things Engineering (ICBAIE), Hangzhou, China, 2023, pp. 205-208, doi: 10.1109/ICBAIE59714.2023.10281232.
4. Ping Wang, Yan Li, and Chandan K. Reddy. 2019. Machine Learning for Survival Analysis: A Survey. ACM Comput. Surv. 51, 6, Article 110 (November 2019), 36 pages. <https://doi.org/10.1145/3214306>
5. Jahanbani Fard, Mahtab & Wang, Ping & Chawla, Sanjay & Reddy, Chandan. (2016). A Bayesian Perspective on Early Stage Event Prediction in Longitudinal Data. IEEE Transactions on Knowledge and Data Engineering. PP. 10.1109/TKDE.2016.2608347.
6. Maxime Amram, Jack Dunn, Jeremy J. Toledano, Ying Daisy Zhuo, Interpretable predictive maintenance for hard drives, Machine Learning with Applications, Volume 5, 2021, ISSN 2666-8270, <https://doi.org/10.1016/j.mlwa.2021.100042>.
7. Jayanta Basak and Randy H. Katz, Significance of Disk Failure Prediction in Datacenters, 2017, <https://arxiv.org/abs/1707.01952>
8. Murray, Joseph & Hughes, Gordon & Kreutz-Delgado, Ken. (2005). Machine Learning Methods for Predicting Failures in Hard Drives: A Multiple-Instance Application.. Journal of Machine Learning Research. 6. 783-816.
9. I. C. Chaves, M. R. P. de Paula, L. G. M. Leite, L. P. Queiroz, J. P. P. Gomes and J. C. Machado, "BaNHFaP: A Bayesian Network Based Failure Prediction Approach for Hard Disk Drives," 2016 5th Brazilian Conference on Intelligent Systems (BRACIS), Recife, Brazil, 2016, pp. 427-432, doi: 10.1109/BRACIS.2016.083.
10. Chaves, Iago. (2018). Hard Disk Drive Failure Prediction Method Based On A Bayesian Network. 10.1109/IJCNN.2018.8489097.